ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas

Carrera de Ciencia de Datos e Inteligencia Artificial

INFORME DE LABORATORIO · SEMANA 3

Clasificación de variables y población vs. muestra

Laboratorio complementario · Semana 3 · Caso RetailAndina S.A.

Asignatura	IDSD422 — Estadística y Programación para Ciencia de Datos I
Estudiante(s)	Valenzuela Tello Esteban Alejandro · **usuario de GitHub**: Esteaban10
Docente	Christian Suarez
Período académico	2026-B
Fecha de entrega	23/10/2026
Repositorio (fork)	https://github.com/EstebanValenzuela10/IDSD422-lab-muestreo-poblacion.git

Laboratorio Complementario · Semana 3 · IDSD422 · 2026-B

1 · Introducción

RetailAndina S.A. tiene una base con los datos de sus clientes frecuentes, como la edad, la ciudad, el nivel de estudios, los ingresos y qué tan satisfechos están. La gerencia quiere saber qué información tiene exactamente y qué se puede hacer con cada dato. Por ejemplo, un ingreso se puede promediar, pero una opinión de 1 a 5 no siempre. También quiere estimar cuánto gana al mes un cliente promedio, pero sin revisar a los 400 clientes, usando solo grupos de 20 y comprobando que ese grupo realmente se parece al total.

Esto importa porque, si un dato se clasifica mal, los cálculos que se hagan con él pueden dar resultados que no significan nada, y si el grupo de 20 clientes se elige mal, revisar más clientes de la misma forma no lo arregla. Para comprobarlo, trabajé en Google Colab con dos archivos. Primero revisé los datos de 12 clientes, miré el tipo que pandas asignó a cada variable y sus valores únicos, y las clasifiqué según si tiene sentido tomar la mitad del valor y si hay un orden entre sus categorías. Después calculé el ingreso promedio real de los 400 clientes de Quito, Guayaquil y Cuenca, y lo comparé con tres muestras de 20, los primeros de la lista, un sorteo al azar y un sorteo por ciudad.

2 · Objetivos

Objetivo general. Clasificar las variables presentadas en los archivos compartidos y comparar tres diseños de muestreo contra el parámetro poblacional del ingreso mensual.

Objetivos específicos:

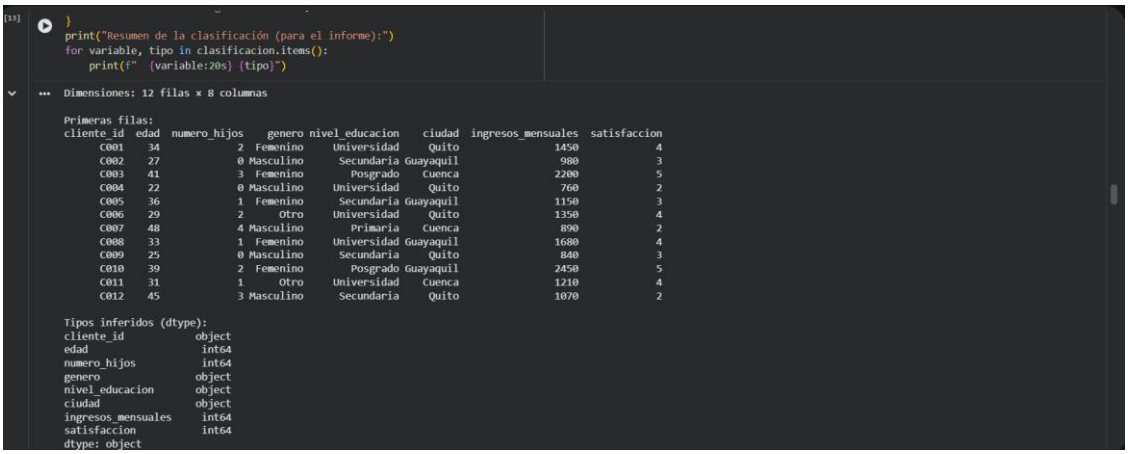
1. Clasificar las 7 variables con el criterio de continuidad y orden, y verificar el tipo en código, dtype y valores únicos.
2. Declarar el orden de las variables ordinales y comprobarlo en código.
3. Calcular el parámetro poblacional e implementar los diseños de conveniencia, aleatorio simple y estratificado, comparando cada media con el parámetro.
4. Interpretar el sesgo (sistemático) y la variabilidad (por sorteo) y reportar los límites de la conclusión.

3 · Desarrollo de la práctica

Trabajé en Google Colab con Python (pandas) y repetí el análisis en R. Las capturas del cuerpo del informe son de Python, las de R están en los Anexos.

3.1 Clasificación de las variables

Cargué clientes.csv (12 filas, 8 columnas), revisé los tipos inferidos (Figura 1) y los valores únicos por columna (Figura 2). Clasifiqué cada variable con dos preguntas: ¿tiene sentido la mitad del valor? y ¿hay orden entre las categorías? Para las ordinales declaré el orden y comprobé el mínimo (Primaria para nivel_educacion; 2 para satisfaccion).



```
[13]
}
print("Resumen de la clasificación (para el informe):")
for variable, tipo in clasificacion.items():
    print(f"  {variable:20s} {tipo}")

...  Dimensiones: 12 filas × 8 columnas

Primeras filas:
cliente_id  edad  numero_hijos    genero nivel_educacion    ciudad  ingresos_mensuales  satisfaccion
      C001    34             2  Femenino     Universidad     Quito                1450             4
      C002    27             0 Masculino      Secundaria Guayaquil                 980             3
      C003    41             3  Femenino        Posgrado    Cuenca                2200             5
      C004    22             0 Masculino     Universidad     Quito                 760             2
      C005    36             1  Femenino      Secundaria Guayaquil                1150             3
      C006    29             2      Otro     Universidad     Quito                1350             4
      C007    48             4 Masculino        Primaria    Cuenca                 890             2
      C008    33             1  Femenino     Universidad Guayaquil                1680             4
      C009    25             0 Masculino      Secundaria     Quito                 840             3
      C010    39             2  Femenino        Posgrado Guayaquil                2450             5
      C011    31             1      Otro     Universidad    Cuenca                1210             4
      C012    45             3 Masculino      Secundaria     Quito                1070             2

Tipos inferidos (dtype):
cliente_id           object
edad                  int64
numero_hijos          int64
genero               object
nivel_educacion      object
ciudad               object
ingresos_mensuales    int64
satisfaccion          int64
dtype: object
```

Figura 1. *Tipos inferidos (dtype) de clientes.csv en Python, satisfaccion llega como int64, aunque es ordinal, nivel_educacion llega como object.*

```
Valores únicos por columna:
  Columna: cliente_id           | Cantidad: 12 | Valores: ['C001' 'C002' 'C003' 'C004' 'C005' 'C006' 'C007' 'C008' 'C009' 'C010'
 'C011' 'C012']
  Columna: edad                 | Cantidad: 12 | Valores: [34 27 41 22 36 29 48 33 25 39 31 45]
  Columna: numero_hijos         | Cantidad: 5 | Valores: [2 0 3 1 4]
  Columna: genero               | Cantidad: 3 | Valores: ['Femenino' 'Masculino' 'Otro']
  Columna: nivel_educacion      | Cantidad: 4 | Valores: ['Universidad' 'Secundaria' 'Posgrado' 'Primaria']
  Columna: ciudad               | Cantidad: 3 | Valores: ['Quito' 'Guayaquil' 'Cuenca']
  Columna: ingresos_mensuales   | Cantidad: 12 | Valores: [1450  980 2200  760 1150 1350  890 1680  840 2450 1210 1070]
  Columna: satisfaccion         | Cantidad: 4 | Valores: [4 3 5 2]

Mínimo nivel de educación: Primaria
Mínima satisfacción: 2
Valores faltantes en nivel_educacion: 0

Resumen de la clasificación (para el informe):
  cliente_id          Categórica nominal (Identificador)
  edad                Numerica discreta
  numero_hijos        Numerica discreta
  genero              Categorica nominal
  nivel_educacion     Categorica ordinal
  ciudad              Categorica nominal
  ingresos_mensuales  Numerica continua
  satisfaccion        Categorica ordinal
```

Figura 2. *Valores únicos por columna, mínimos de las ordinales y resumen de la clasificación (Python).*

Variable	Tipo	Justificación (criterio)	Verificación en código
cliente_id	Identificador (categórica nominal)	Es solo un código para distinguir a cada cliente. No tiene sentido sumarlo, promediarlo ni calcular su mitad.	object; 12 únicos en 12 filas
edad	Numérica discreta	La base la registra en años cumplidos (22, 27, 34), sin fracciones. La mitad (17 años) sí tiene sentido y 0 es ausencia, por eso es de razón, la edad real es continua, pero aquí se mide en enteros, por lo que la traté como discreta.	int64; 12 únicos; rango 22 a 48
numero_hijos	Numérica discreta	Es un conteo: se cuentan hijos enteros. No existe un cliente con 2,5 hijos.	int64; 5 únicos (0 a 4)
genero	Categórica nominal	Son categorías (Femenino, Masculino, Otro) y ninguna va antes que otra. Solo sirven para agrupar.	object; 3 únicos (Femenino, Masculino, Otro)
nivel_educacion	Numérica ordinal	Hay orden (Primaria < Secundaria < Universidad < Posgrado), pero no una distancia fija ni una «mitad».	object; 4 únicos; orden declarado; mínimo = Primaria
ciudad	Categórica nominal	Son categorías, pero con un orden Primaria, Secundaria, Universidad, Posgrado. No se puede tomar la mitad de Universidad ni decir cuánta distancia hay entre un nivel y otro.	object; 3 únicos

ingresos_mensuales	Numérica continua	Es un monto de dinero, tiene sentido su mitad y puede tomar cualquier valor, no solo enteros (por ejemplo, 1 450,50).	int64; 12 únicos; rango 760 a 2450
satisfaccion	Categórica ordinal	Aunque son números (2 a 5), representan una opinión con orden, 5 es más satisfecho que 4. Pero no se sabe si la diferencia entre 4 y 5 es igual a la de 2 y 3, y la mitad de 4 no significa nada. Los números son solo etiquetas.	int64 (engaña); 4 únicos (2, 3, 4, 5); mínimo = 2

Tabla 1. *Tabla de variables y su clasificación entre numérica o categórica y su justificación.*

P1. ¿Qué me dijo el dtype de satisfaccion y por qué no basta?

Como se puede observar en la figura 1 pandas la leyó como número. Pero el dtype describe cómo se guardó el dato, no qué significa. Los valores únicos son 4, 3, 5 y 2 (Figura 2), una escala de opinión en la que no sé si la distancia de 4 a 5 equivale a la de 2 a 3, así que promediarla sería erroneo. Con nivel_educacion pasó lo contrario, llegó como object (texto) y sus valores únicos aparecen en orden de aparición (Universidad, Secundaria, Posgrado, Primaria), sin jerarquía. Si queda como texto sin declarar el orden, un máximo, un mínimo o un ordenamiento usaría el orden alfabético (Posgrado antes que Primaria) y daría resultados falsos. Al declarar el orden, el mínimo salió Primaria, como corresponde.

3.2 Población vs. muestra

Cargué clientes_400.csv y calculé el parámetro. Luego corrí los tres diseños con n = 20 (el 5 % de 400): conveniencia con *head(20),* aleatorio simple con *sample(n=20)* y estratificado con *groupby("ciudad") + frac=0.05*, usando la semilla 1 en Python (Figura 3). En R usé slice_sample (Anexos , Figura 8).

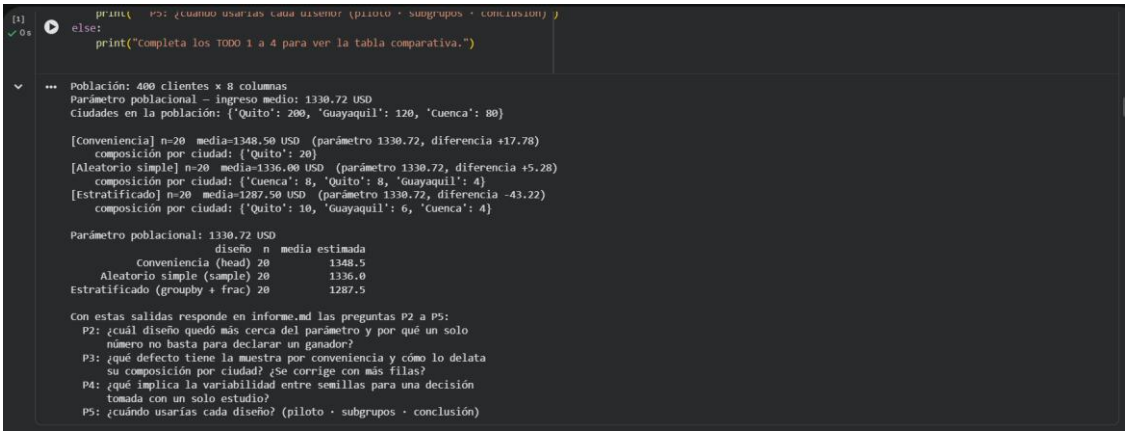


Figura 3. *Parámetro poblacional y los tres diseños en Python: head(20) devolvió 20 clientes de Quito.*

Concepto	Valor
Población (N)	400 clientes (Quito 200 / Guayaquil 120 / Cuenca 80)
Variable de interés	ingresos_mensuales (numérica continua)
Parámetro poblacional (media)	1330,725
¿Por qué se muestrea si aquí el parámetro existe y se calculó?	Aquí lo calculé porque tenía los 400 registros, y sirve para evaluar los diseños. En la práctica la empresa no tendría todos los ingresos (o medirlos costaría tiempo y dinero) y el parámetro sería desconocido, la muestra sirve para estimarlo.

Tabla 2. *Identificación de la muestra y variable de interés y cálculo del parámetro poblacional.*

Diseño (Python, semilla 1)	n	Media estimada	Composición por ciudad	Diferencia vs. parámetro	% del parámetro
Conveniencia (head)	20	1348,50	Quito 20 · Guayaquil 0 · Cuenca 0	+17,78	+1,3 %
Aleatorio simple (sample)	20	1336,00	Quito 8 · Guayaquil 4 · Cuenca 8	+5,28	+0,4 %
Estratificado (groupby + 5 %)	20	1287,50	Quito 10 · Guayaquil 6 · Cuenca 4	−43,22	−3,2 %

Tabla 3. *Cálculo de la media estimada en los tres tipos de muestreo.*

En R (Figura 8) obtuve: conveniencia 1 348,50 (+17,78); aleatorio simple 1 318,00 (−12,72), con Quito 8 · Guayaquil 7 · Cuenca 5; y estratificado 1 226,00 (−104,72), con Quito 10 · Guayaquil 6 · Cuenca 4.

Medias de 5 sorteos distintos del aleatorio simple en Python (n = 20, semillas 1 a 5; la semilla 1 coincide con la Figura 3):

Semilla	1	2	3	4	5
Media	1336,00	1405,00	1235,00	1491,50	1288,00
Diferencia vs. parámetro	+5,28	+74,28	−95,72	+160,78	−42,72

Tabla 4. *Diferencia de la media en el muestreo aleatorio simple mediante 5 semillas.*

```
print("Variabilidad con diferentes semillas (Muestra Aleatoria Simple):")
for semilla in [1, 2, 3, 4, 5]:
    muestra_temp = poblacion.sample(20, random_state=semilla)
    media_temp = muestra_temp["ingresos_mensuales"].mean()
    print(f"  Semilla {semilla} -> Media estimada: {media_temp:.2f} USD (Diferencia: {media_temp - parametro:+.2f} USD)")
print()
```

```
Variabilidad con diferentes semillas (Muestra Aleatoria Simple):
  Semilla 1 -> Media estimada: 1336.00 USD (Diferencia: +5.28 USD)
  Semilla 2 -> Media estimada: 1405.00 USD (Diferencia: +74.28 USD)
  Semilla 3 -> Media estimada: 1235.00 USD (Diferencia: -95.72 USD)
  Semilla 4 -> Media estimada: 1491.50 USD (Diferencia: +160.78 USD)
  Semilla 5 -> Media estimada: 1288.00 USD (Diferencia: -42.72 USD)
```

Figura 4. *Medias del aleatorio simple con semillas 1 a 5 (Python): van de 1 235,00 a 1 491,50.*

P2. ¿Cuánto vale el parámetro y cuánto estimó cada diseño? ¿Cuál quedó más cerca?

El parámetro es 1 330,72. La conveniencia estimó 1348,50 (+17,78), el aleatorio simple 1 336,00 (+5,28) y el estratificado 1287,50 (−43,22. El aleatorio simple quedó más cerca en ambos lenguajes, pero eso no alcanza para determinarlo como mejor, es una sola corrida por lenguaje, y el estratificado, que tuvo la composición más parecida a la población (10/6/4), fue el más lejano en las dos. Con otra semilla el orden cambia. Además, la conveniencia quedó más cerca que el estratificado siendo el diseño defectuoso: acercarse al parámetro por casualidad no prueba que el método sea válido.

P3. ¿Qué defecto tiene la muestra por conveniencia y cómo lo delaté? ¿Se corrige con más filas?

En esta parte head(20) devolvió los primeros 20 registros, y el archivo está ordenado por ciudad, los 20 son de Quito (Figura 3), que es el 50 % de la población, y Guayaquil y Cuenca quedaron con 0. Lo delató la composición por ciudad. Es un sesgo sistemático, en la población, Quito promedia 1390,50 y Cuenca 1193,50, así que esta muestra tiende a sobreestimar, unos +60 sobre el parámetro. Que su

media diera +17,78 fue suerte dentro de Quito, no mérito del método. Con más filas no se corrige: head(100) seguiría siendo solo Quito, y head(200) también, el defecto está en cómo se eligió, no en cuántos se eligieron.

P4. ¿Qué implica la variabilidad entre semillas para una empresa que decide con un solo estudio?

Implica que un estudio con n = 20 es una de muchas medias posibles: con las semillas 1 a 5 obtuve entre 1 235,00 y 1 491,50, un rango de 256,50. Incluso el mismo diseño dio 1 336,00 en Python y 1 318,00 en R, porque los generadores y semillas producen sorteos distintos. A diferencia del sesgo de la conveniencia, esta variabilidad no es sistemática, se compensa en promedio y baja con una muestra más grande.

P5. ¿Cuándo usaría cada diseño?

- **Conveniencia:** para una exploración rápida, probar un cuestionario, ver cómo se ven los datos, sin generalizar a toda la población.
- **Aleatorio simple:** cuando hay que concluir sobre toda la población y no hay subgrupos críticos, cada cliente tiene la misma probabilidad de entrar.
- **Estratificado:** cuando hay subgrupos que deben aparecer en su proporción. En 1 000 repeticiones su desviación fue 86,60, similar a la del aleatorio simple (89,60), y garantiza que ninguna ciudad quede sin representar.

4 · ¿Qué aprendí con esta práctica?

Ahora entiendo por qué el dtype no alcanza para clasificar una variable, satisfaccion llegó como int64 y es ordinal, y nivel_educacion llegó como texto sin jerarquía. Aprendí a declarar el orden y a comprobarlo con el mínimo. Lo más difícil fue aceptar que la media de head(20) quedara cerca del parámetro y aun así el diseño fuera malo, lo entendí al ver la composición por ciudad. También me sorprendió que mi estratificado, con la composición perfecta, quedara más lejos que el aleatorio simple, lo resolví repitiendo los sorteos con varias semillas y viendo que una sola corrida no decide. La próxima vez revisaré cómo está ordenado el archivo antes de tomar cualquier muestra y reportaré siempre el margen de variabilidad junto con la media.

5 · Conclusiones

1. De las 7 variables, 3 son numéricas (edad y numero_hijos discretas; ingresos_mensuales continua), 2 son categóricas nominales (genero, ciudad) y 2 son categóricas ordinales (nivel_educacion con 4 niveles y satisfaccion con valores 2 a 5). El dtype solo ayudó con las numéricas; satisfaccion (int64) y nivel_educacion (texto) requirieron declarar el orden.
2. El parámetro es 1 330,72 (N = 400). La conveniencia (1 348,50) tomó 20 de 20 clientes de Quito, frente al 50 % de la población, con un sesgo esperado de unos +60 que no se corrige con más filas. El aleatorio simple (1 336,00; +5,28) y el estratificado (1 287,50; −43,22) usaron clientes de las tres ciudades.
3. Con n = 20, las medias aleatorias fueron de 1 235,00 a 1 491,50 (semillas 1–5) y, en 1 000 sorteos, la desviación fue 90. Esa variabilidad es del sorteo y se reduce con n; el sesgo es del diseño y no.

Respuesta a la gerencia y alcance. Con esta base de 400 clientes de Quito, Guayaquil y Cuenca, una muestra de 20 clientes elegida al azar estratificada por ciudad puede estimar el ingreso mensual promedio con un error típico cercano a 90, una muestra por conveniencia no sirve para esa conclusión. Estos resultados aplican a esta base y a estos diseños, no a otras ciudades ni a otros períodos. La lección central: el diseño decide, no el tamaño.

6 · Bibliografía

Bruce, P., Bruce, A. y Gedeck, P. (2020). *Practical Statistics for Data Scientists* (2.ª ed.). O'Reilly.

Pandas development team. (2026). *pandas.CategoricalDtype*. https://pandas.pydata.org/docs/reference/api/pandas.CategoricalDtype.html

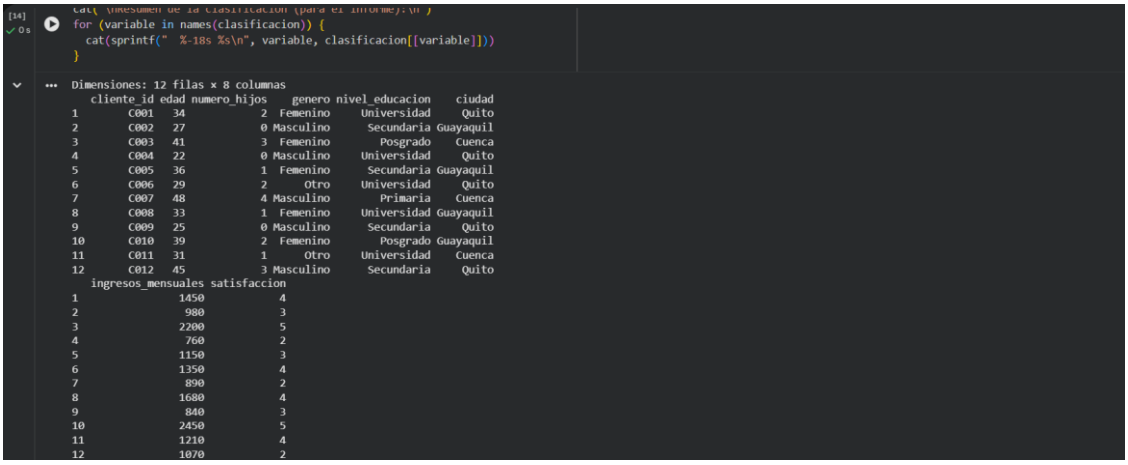
Pandas development team. (2026). *pandas.DataFrame.sample*. https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.sample.html

Documentación de dplyr: https://dplyr.tidyverse.org/

Docente de IDSD422. (2026). *clientes.csv* y *clientes_400.csv* [conjuntos de datos]. Repositorio del laboratorio, Escuela Politécnica Nacional.

Declaración de uso de IA. Usé Gemini 4 para que me realice el bucle for de la figura 4 para que me de los valores de las 5 semillas.

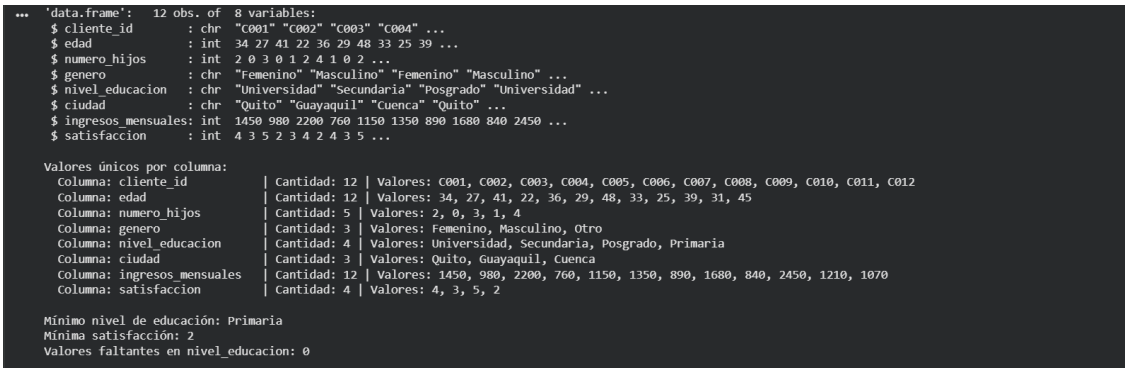
7 · Anexos



```
[14]
✓ 0s
for (variable in names(clasificacion)) {
  cat(sprintf("  %-18s %s\n", variable, clasificacion[[variable]]))
}

Dimensiones: 12 filas x 8 columnas
   cliente_id edad numero_hijos    genero nivel_educacion    ciudad
1        C001   34            2  Femenino     Universidad     Quito
2        C002   27            0 Masculino      Secundaria Guayaquil
3        C003   41            3  Femenino        Posgrado    Cuenca
4        C004   22            0 Masculino     Universidad     Quito
5        C005   36            1  Femenino      Secundaria Guayaquil
6        C006   29            2      Otro     Universidad     Quito
7        C007   48            4 Masculino        Primaria    Cuenca
8        C008   33            1  Femenino     Universidad Guayaquil
9        C009   25            0 Masculino      Secundaria     Quito
10       C010   39            2  Femenino        Posgrado Guayaquil
11       C011   31            1      Otro     Universidad    Cuenca
12       C012   45            3 Masculino      Secundaria     Quito
   ingresos_mensuales satisfaccion
1                1450            4
2                 980            3
3                2200            5
4                 760            2
5                1150            3
6                1350            4
7                 890            2
8                1680            4
9                 840            3
10               2450            5
11               1210            4
12               1070            2
```

Figura 5. *clientes.csv cargado en R: 12 filas × 8 columnas.*



```
'data.frame':   12 obs. of  8 variables:
 $ cliente_id        : chr  "C001" "C002" "C003" "C004" ...
 $ edad              : int  34 27 41 22 36 29 48 33 25 39 ...
 $ numero_hijos      : int  2 0 3 0 1 2 4 1 0 2 ...
 $ genero            : chr  "Femenino" "Masculino" "Femenino" "Masculino" ...
 $ nivel_educacion   : chr  "Universidad" "Secundaria" "Posgrado" "Universidad" ...
 $ ciudad            : chr  "Quito" "Guayaquil" "Cuenca" "Quito" ...
 $ ingresos_mensuales: int  1450 980 2200 760 1150 1350 890 1680 840 2450 ...
 $ satisfaccion      : int  4 3 5 2 3 4 2 4 3 5 ...

Valores únicos por columna:
  Columna: cliente_id           | Cantidad: 12 | Valores: C001, C002, C003, C004, C005, C006, C007, C008, C009, C010, C011, C012
  Columna: edad                 | Cantidad: 12 | Valores: 34, 27, 41, 22, 36, 29, 48, 33, 25, 39, 31, 45
  Columna: numero_hijos         | Cantidad: 5 | Valores: 2, 0, 3, 1, 4
  Columna: genero               | Cantidad: 3 | Valores: Femenino, Masculino, Otro
  Columna: nivel_educacion      | Cantidad: 4 | Valores: Universidad, Secundaria, Posgrado, Primaria
  Columna: ciudad               | Cantidad: 3 | Valores: Quito, Guayaquil, Cuenca
  Columna: ingresos_mensuales   | Cantidad: 12 | Valores: 1450, 980, 2200, 760, 1150, 1350, 890, 1680, 840, 2450, 1210, 1070
  Columna: satisfaccion         | Cantidad: 4 | Valores: 4, 3, 5, 2

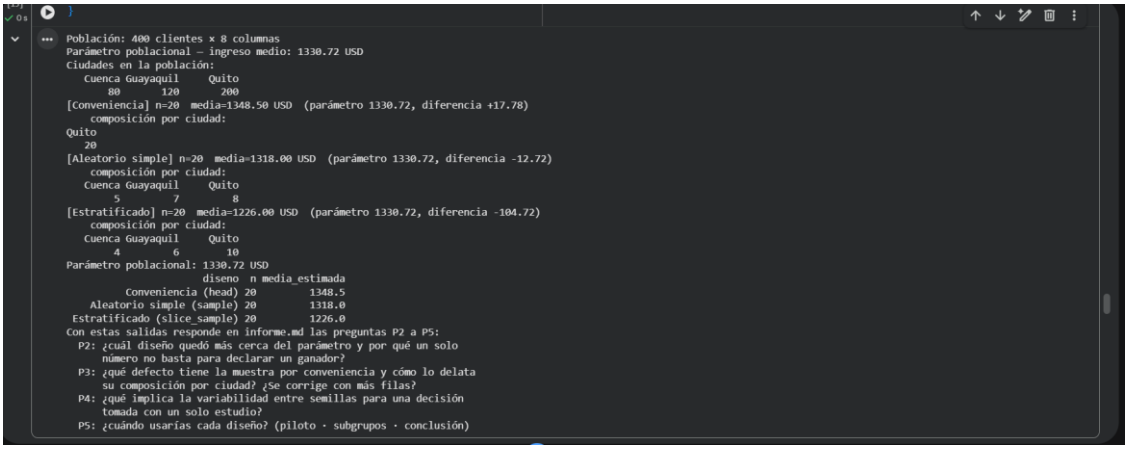
Mínimo nivel de educación: Primaria
Mínima satisfacción: 2
Valores faltantes en nivel_educacion: 0
```

Figura 6. *str() y valores únicos en R: satisfaccion llega como int; nivel_educacion como chr; mínimo = Primaria.*



```
Resumen de la clasificación (para el informe):
  cliente_id         Categorica nominal (Identificador)
  edad               Numerica discreta
  numero_hijos       Numerica discreta
  genero             Categorica nominal
  nivel_educacion    Categorica ordinal
  ciudad             Categorica nominal
  ingresos_mensuales Numerica continua
  satisfaccion       Categorica ordinal
```

Figura 7. *Resumen de la clasificación de las 7 variables (R).*



```
✓ 0s
}

Población: 400 clientes x 8 columnas
Parámetro poblacional — ingreso medio: 1330.72 USD
Ciudades en la población:
   Cuenca Guayaquil     Quito
        80       120       200
[Conveniencia] n=20  media=1348.50 USD  (parámetro 1330.72, diferencia +17.78)
    composición por ciudad:
Quito
   20
[Aleatorio simple] n=20  media=1318.00 USD  (parámetro 1330.72, diferencia -12.72)
    composición por ciudad:
   Cuenca Guayaquil     Quito
         5         7         8
[Estratificado] n=20  media=1226.00 USD  (parámetro 1330.72, diferencia -104.72)
    composición por ciudad:
   Cuenca Guayaquil     Quito
         4         6        10
Parámetro poblacional: 1330.72 USD
                        diseno  n media_estimada
          Conveniencia (head) 20         1348.5
    Aleatorio simple (sample) 20         1318.0
 Estratificado (slice_sample) 20         1226.0
Con estas salidas responde en informe.md las preguntas P2 a P5:
  P2: ¿cuál diseño quedó más cerca del parámetro y por qué un solo
      número no basta para declarar un ganador?
  P3: ¿qué defecto tiene la muestra por conveniencia y cómo lo delata
      su composición por ciudad? ¿Se corrige con más filas?
  P4: ¿qué implica la variabilidad entre semillas para una decisión
      tomada con un solo estudio?
  P5: ¿cuándo usarías cada diseño? (piloto · subgrupos · conclusión)
```

Figura 8. *Parámetro y tres diseños en R: conveniencia 1 348,50; aleatorio simple 1 318,00; estratificado 1 226,00 (slice_sample).*

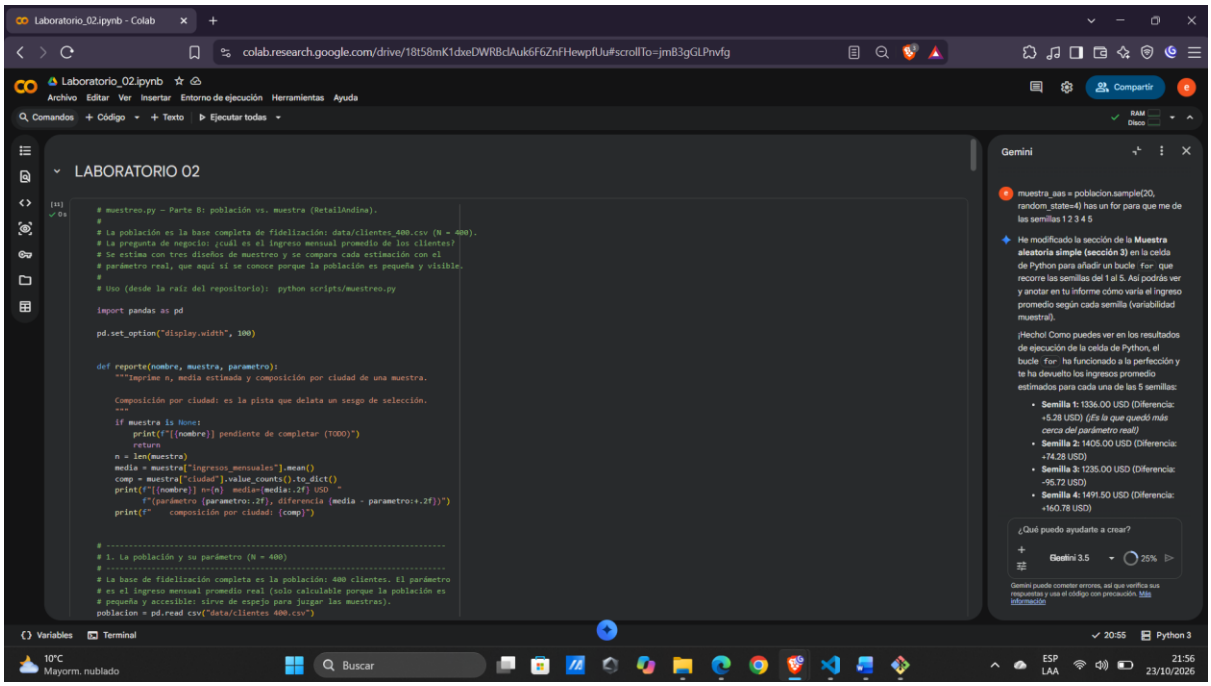


Figura 9. *Código en Python de la Parte B: función de reporte y carga de la población (N = 400).*

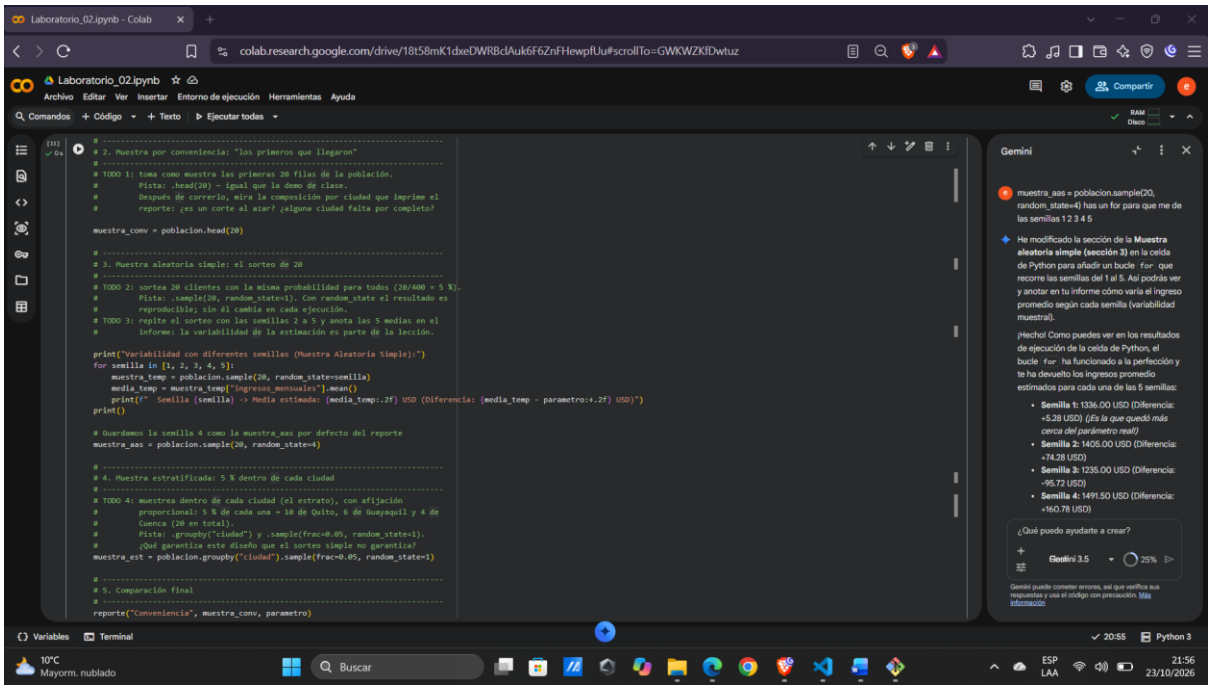


Figura 10. *Código en Python de la Parte B: muestras por conveniencia (head), aleatorio simple con semillas 1 a 5 y estratificado (groupby + 5 %).*

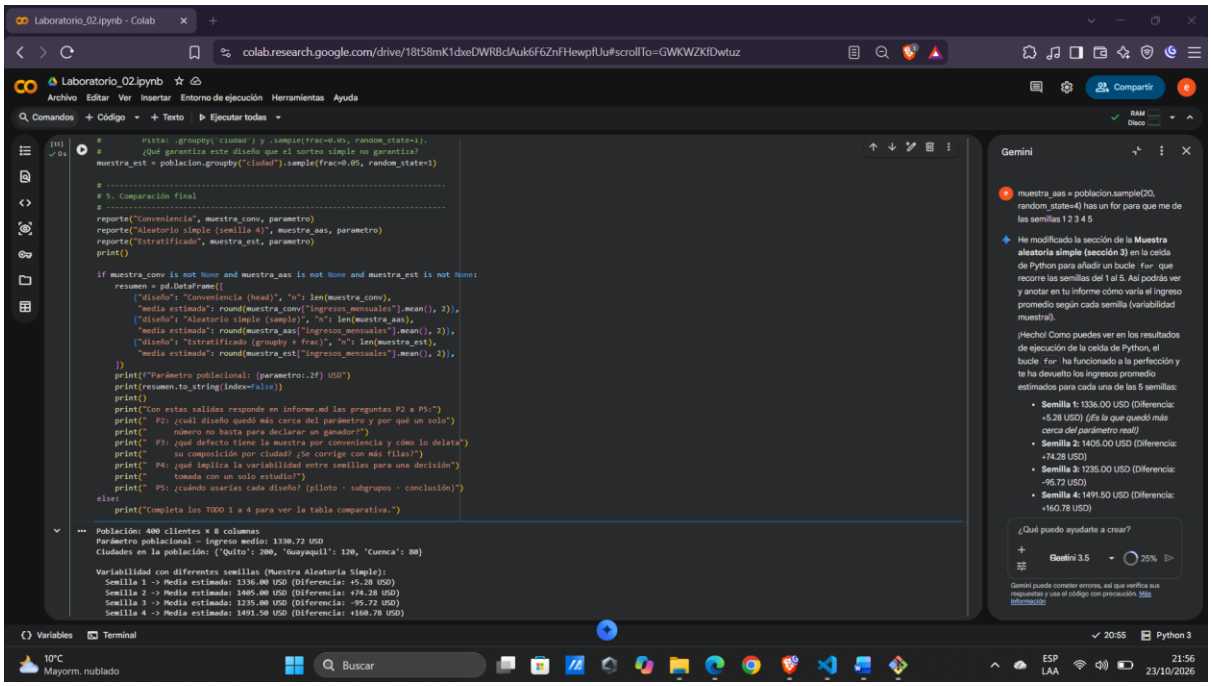


Figura 11. *Código en Python de la Parte B: comparación final de los tres diseños y salida con el parámetro y las medias de las semillas 1 a 4.*

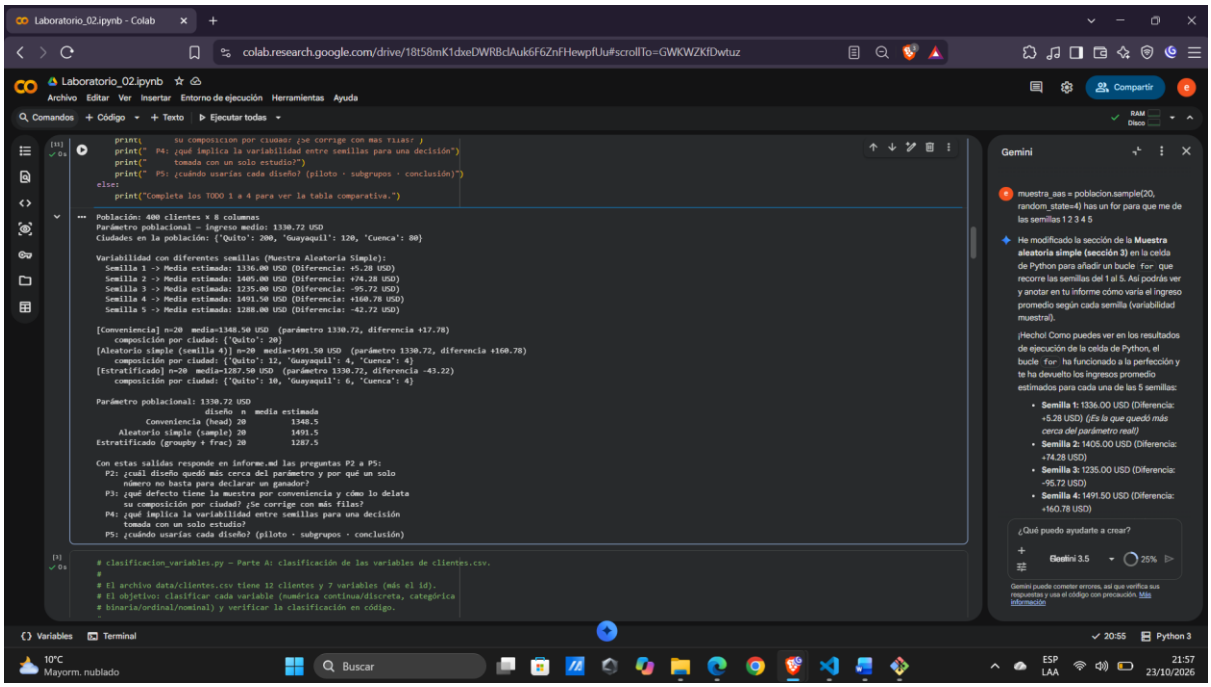


Figura 12. *Salida en Python de la Parte B: medias de las semillas 1 a 5 y composición por ciudad de los tres diseños (el reporte guarda la semilla 4 como aleatorio simple).*

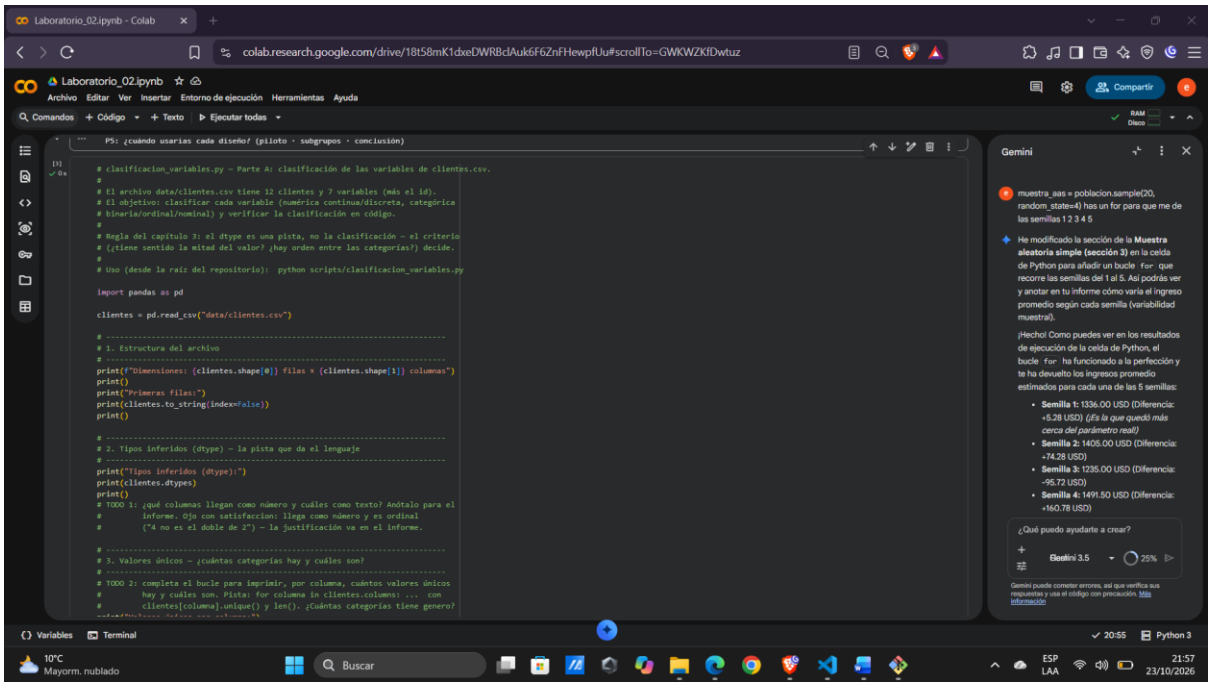


Figura 13. *Código en Python de la Parte A: carga de clientes.csv, tipos inferidos (dtypes) y valores únicos por columna.*

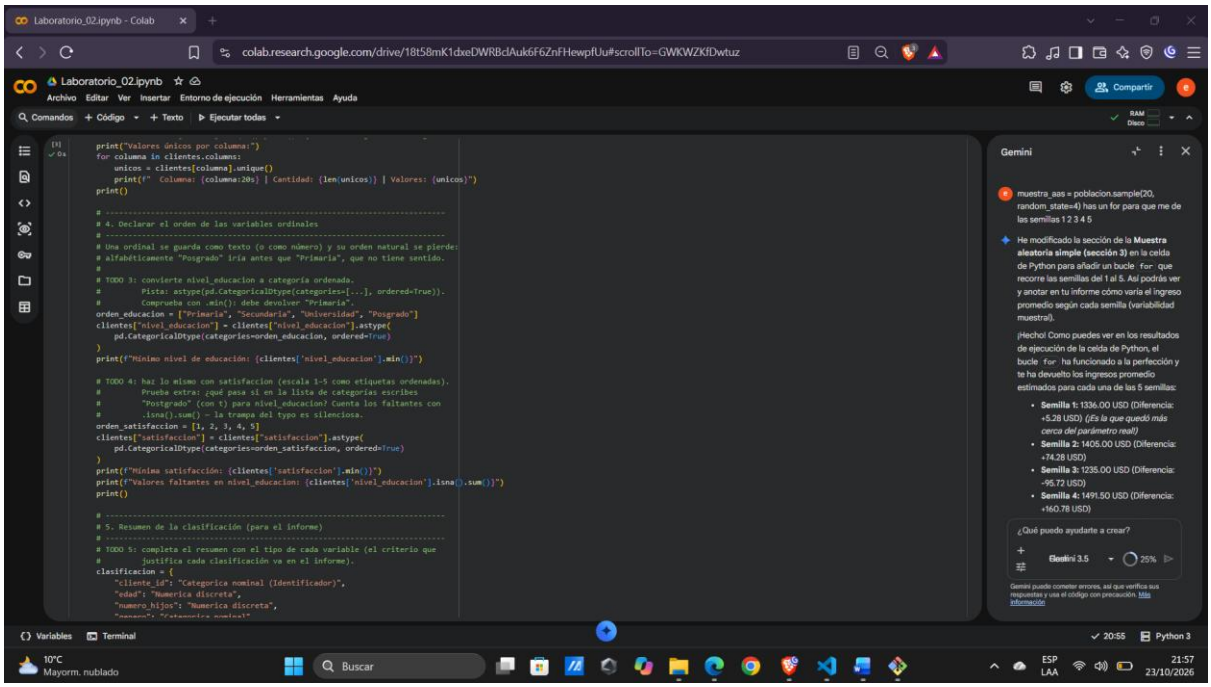


Figura 14. *Código en Python de la Parte A: orden declarado de nivel_educacion y satisfaccion con CategoricalDtype y resumen de la clasificación.*

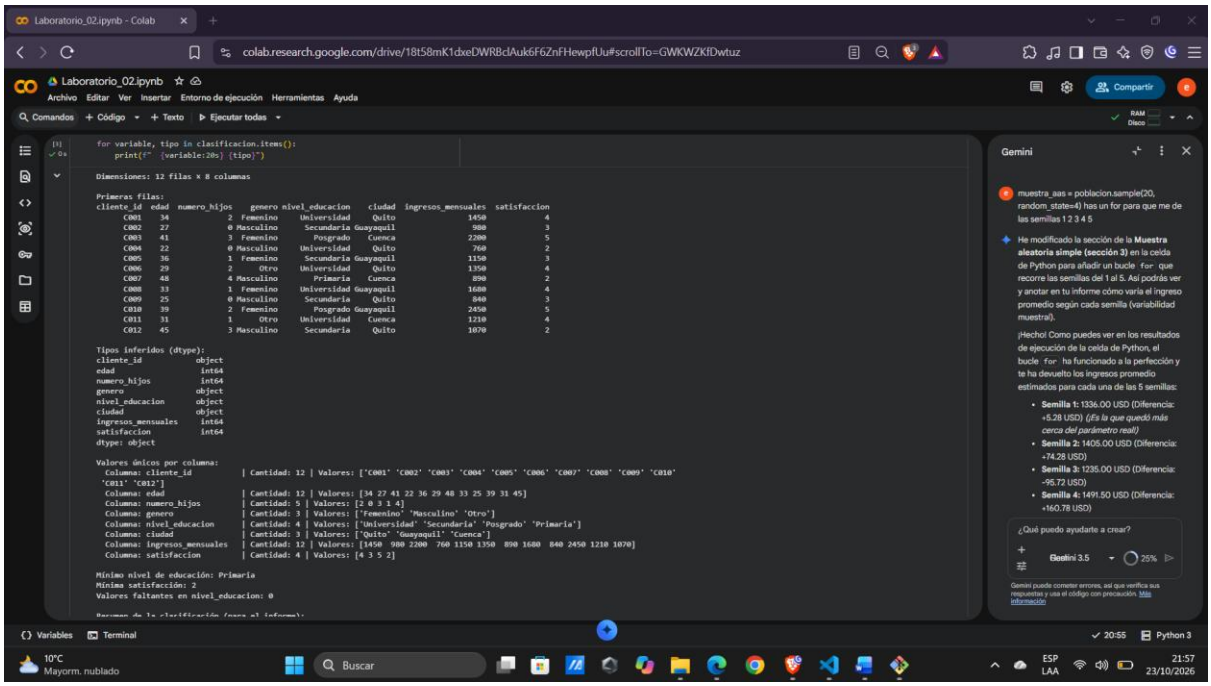


Figura 15. *Salida en Python de la Parte A: dimensiones, dtypes, valores únicos por columna y mínimos de las ordinales.*

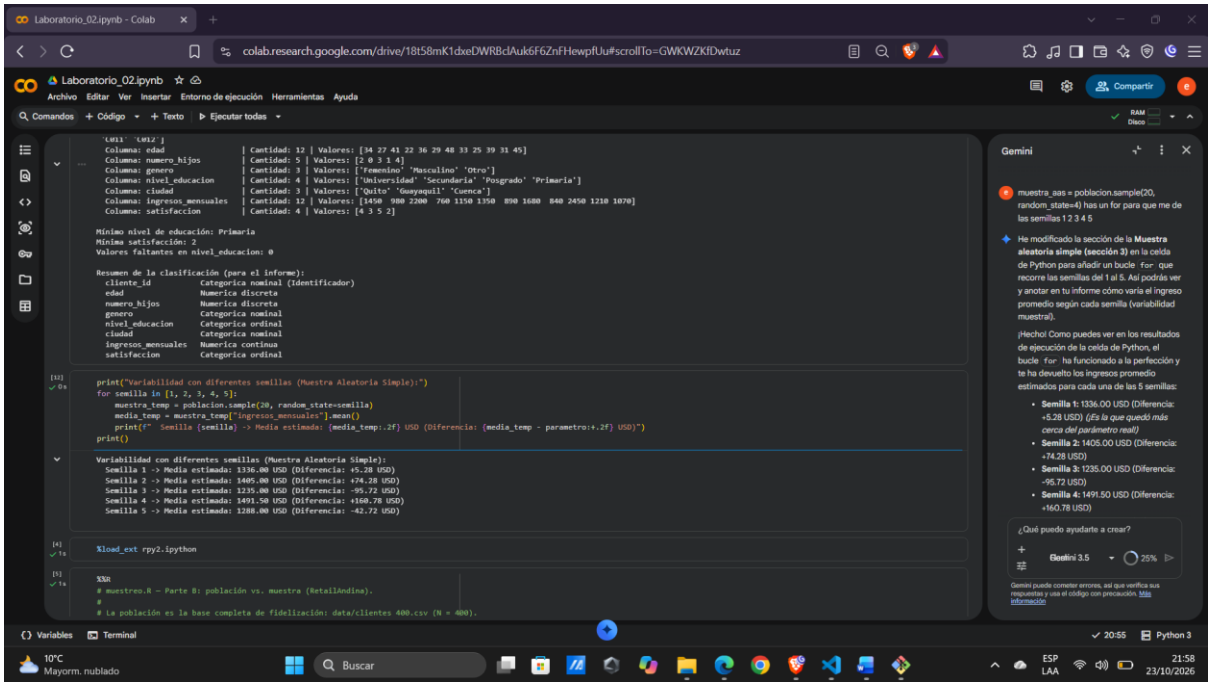


Figura 16. *Salida en Python de la Parte A: resumen de la clasificación y bucle de las semillas 1 a 5 con su salida.*

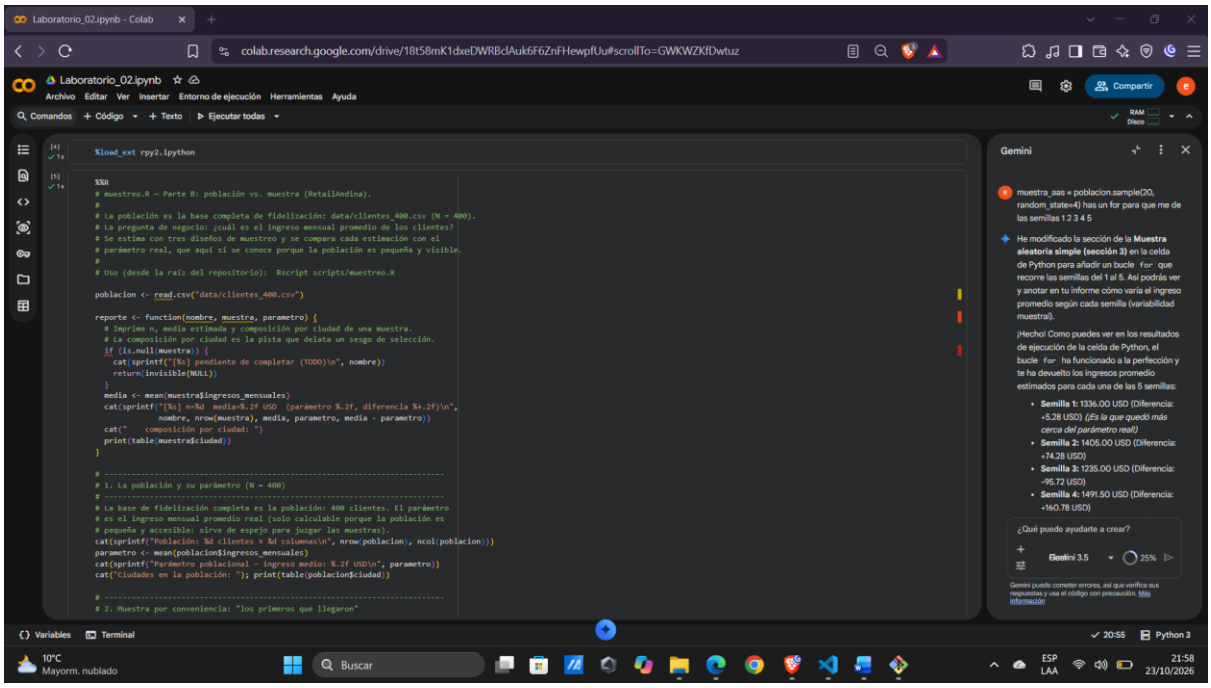


Figura 17. *Código en R de la Parte B: función de reporte, carga de la población y parámetro poblacional.*

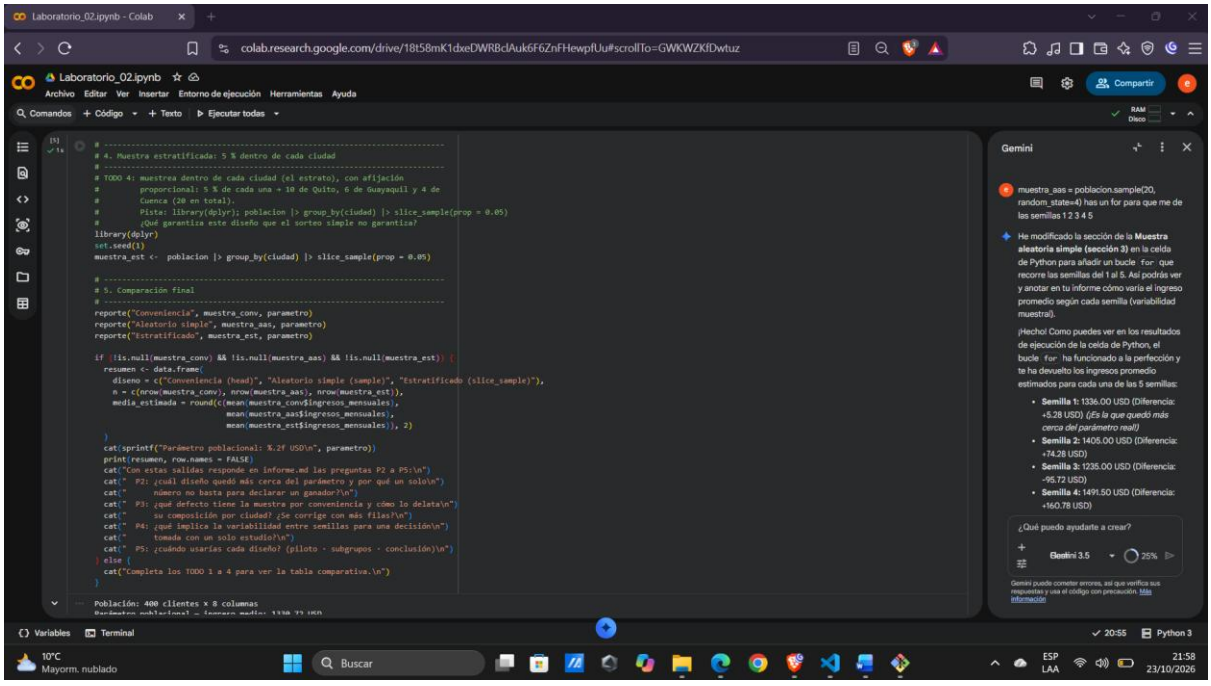


Figura 18. *Código en R de la Parte B: muestra estratificada con group_by y slice_sample (prop = 0,05) y comparación final.*

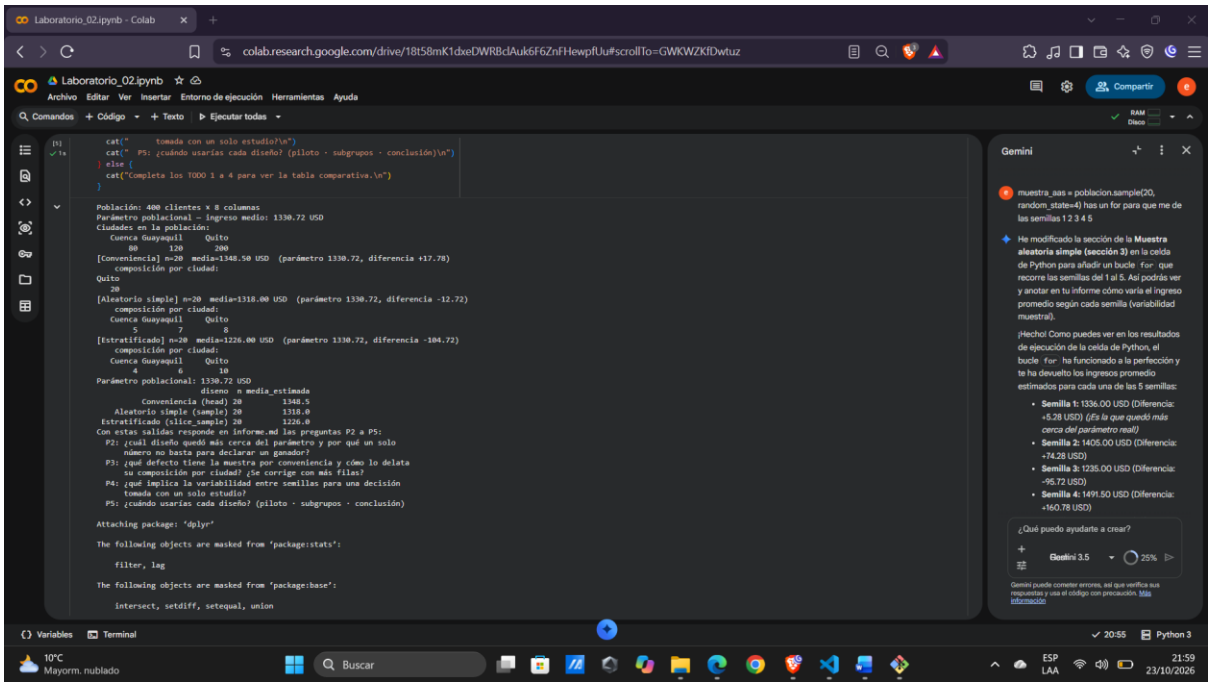


Figura 19. *Salida en R de la Parte B: parámetro, composición por ciudad y media de cada diseño (conveniencia 1 348,50; aleatorio simple 1 318,00; estratificado 1 226,00).*

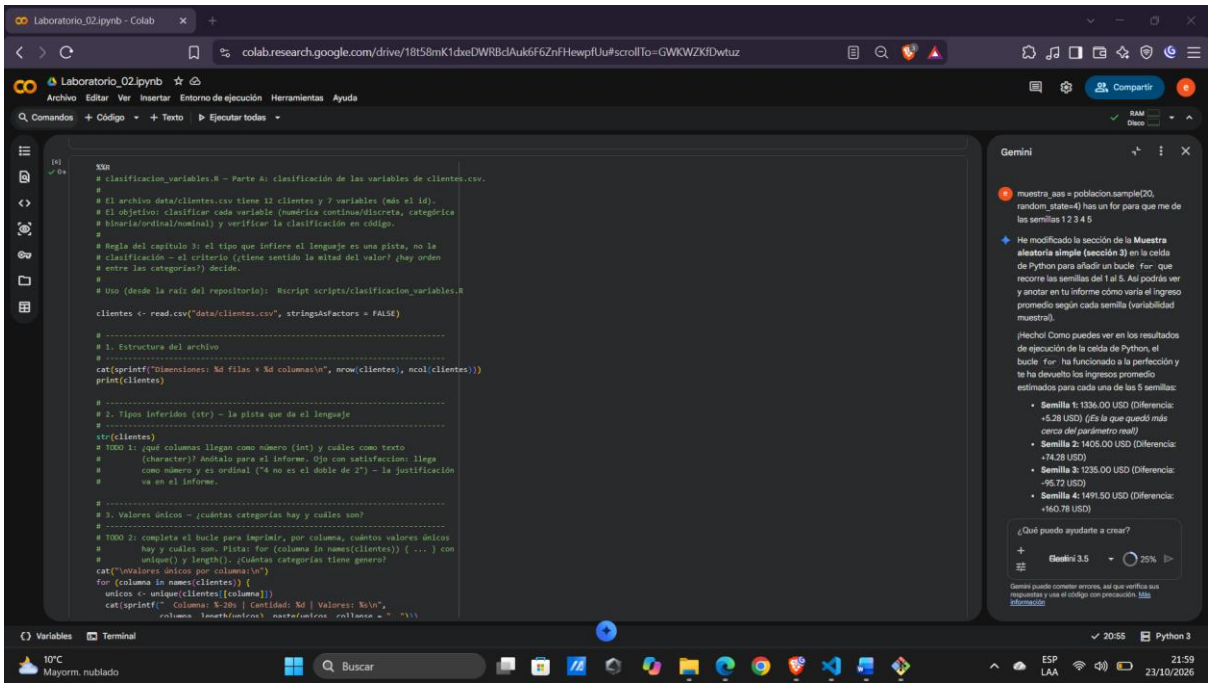


Figura 20. *Código en R de la Parte A: carga de clientes.csv, str() y valores únicos por columna.*

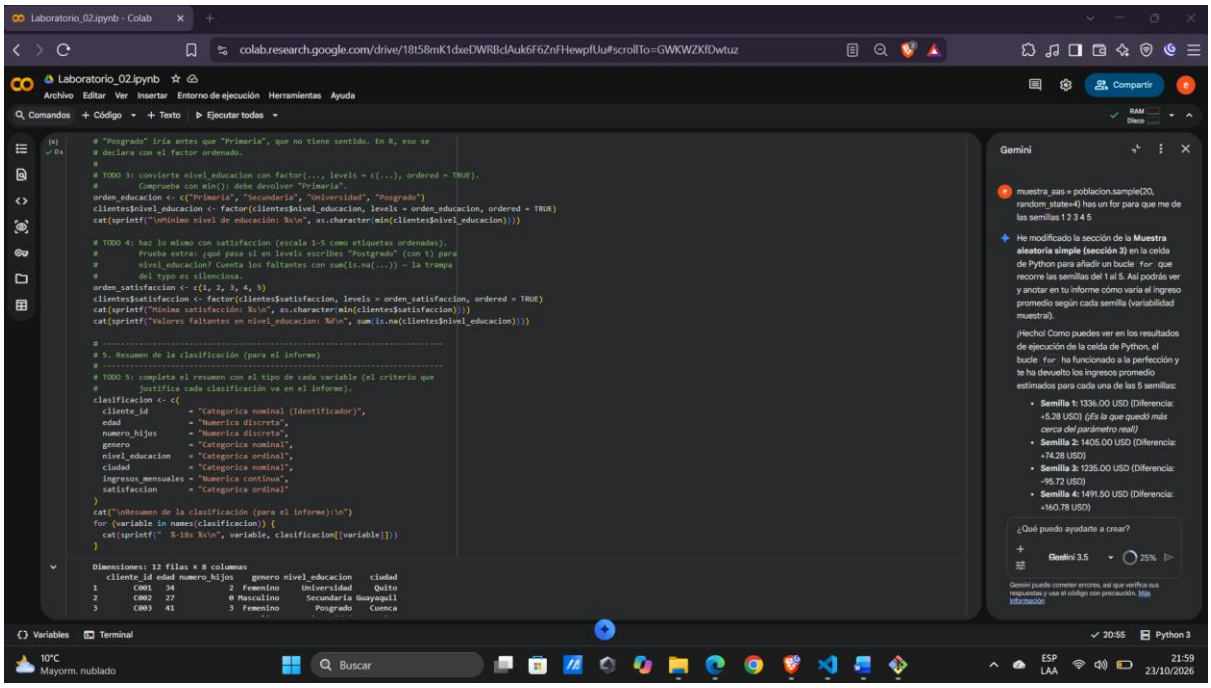


Figura 21. *Código en R de la Parte A: factores ordenados de nivel_educacion y satisfaccion y resumen de la clasificación.*

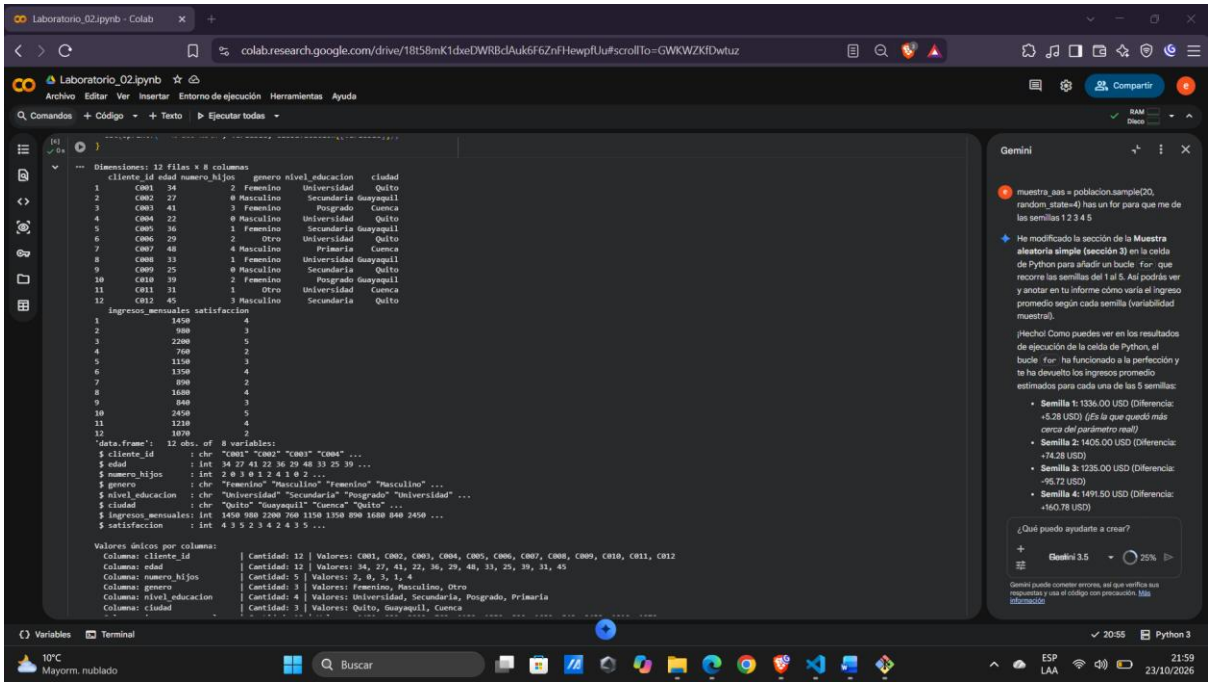


Figura 22. *Salida en R de la Parte A: datos, str() y valores únicos por columna.*